

Project: LASSO Theory & Implementation

Paul ANDREIS, Briac ANGOT, Léo CHENG,
Adrien GENTILI, Emilie LE-NHU,
Juan Carlos PRIETO CALDERON, Cédric-Yséry ZEITER

29 mai 2026

Table des matières

1	Préliminaires	2
1.1	Définition et Algorithme de résolution du LASSO	2
1.1.1	Définition formelle	2
1.1.2	Algorithme de résolution (Approche historique)	2
1.2	Choix du paramètre de régularisation par Validation Croisée	3
2	Exemple historique : Toy Example	4
2.1	Présentation des données simulées	4
2.2	Chemin de régularisation et perspective prédictive	4
2.3	Analyse de la parcimonie (Sparsity)	6
3	Application au monde réel : Diagnostic du cancer du sein	6
3.1	Description du jeu de données	6
3.2	Modèle LASSO Logistique	7
3.3	Estimateur LASSO logistique et chemin de régularisation	7
3.4	Choix de λ par validation croisée	8
3.5	Évaluation des prédictions sur un ensemble de test	9
3.6	Interprétation des variables sélectionnées	9
3.7	Stabilité de sélection des variables	9
3.8	Comparaison entre LASSO, Ridge et Elastic Net	9
3.9	Extension : cadre haute dimensionnel (GSE96058)	10
4	Conclusion	10
A	Cross Validation	11
B	Application au monde réel : Diagnostic du cancer du sein	11
B.1	Comparaison entre LASSO, Ridge et Elastic Net	11
B.2	Extension : cadre haute dimensionnel (GSE96058)	11
C	Chemin de régularisation	12
D	Génération des figures avec la seed 67	13

Résumé

Ce rapport présente une étude approfondie de l'estimateur LASSO, alliant théorie statistique et implémentation computationnelle. Dans un premier temps, nous exposons les principes algorithmiques de la méthode ainsi que les enjeux de la sélection du paramètre de régularisation par validation croisée. Nous reproduisons ensuite l'expérience séminale de TIBSHIRANI [1] sur un modèle synthétique afin d'analyser la trajectoire de régularisation et d'évaluer l'impact de l'hyperparamètre λ sur la parcimonie du modèle et ses performances prédictives. Enfin, nous appliquerons le LASSO sur le jeu de données clinique *Breast Cancer Wisconsin* [2]. Le modèle logistique pénalisé obtient une accuracy de 96.5% et une AUC de 0.997 sur l'ensemble de test, tout en sélectionnant seulement 21 variables sur 30, ce qui illustre la capacité du LASSO à conjuguer performance prédictive et interprétabilité. L'intégralité du code est disponible sur le lien GitHub suivant : https://github.com/cedriczeiter/HISTA_Project.

1 Préliminaires

1.1 Définition et Algorithme de résolution du LASSO

1.1.1 Définition formelle

Considérons le cadre classique de la régression linéaire avec des données (x^i, y_i) pour $i = 1, 2, \dots, N$, où les $x^i = (x_{i1}, \dots, x_{ip})^T$ sont les variables explicatives et y_i les labels. En supposant que les observations sont standardisées, l'estimateur LASSO (Least Absolute Shrinkage and Selection Operator) $(\hat{\alpha}, \hat{\beta})$ est défini par la minimisation de la somme des carrés des résidus sous une contrainte sur la norme L_1 des coefficients :

$$(\hat{\alpha}, \hat{\beta}) = \arg \min \left\{ \sum_{i=1}^N (y_i - \alpha - \sum_j \beta_j x_{ij})^2 \right\} \quad \text{sous la contrainte} \quad \sum_j |\beta_j| \leq t$$

Ici, $t \geq 0$ est un paramètre d'ajustement (tuning parameter) qui contrôle l'intensité de la pénalité (shrinkage) appliquée aux coefficients. À cause de la nature de cette contrainte, le LASSO a la particularité de forcer certains coefficients à être nuls, ce qui permet de rendre les modèles plus facilement interprétables.

Cette formulation contrainte est équivalente, pour une valeur appropriée du paramètre, à la formulation pénalisée

$$\hat{\beta}_\lambda = \arg \min_{\beta} \left\{ \sum_{i=1}^N (y_i - \alpha - x_i^\top \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

Dans la suite, nous utilisons principalement la notation λ pour désigner l'intensité de la pénalisation : plus λ est grand, plus la pénalisation est forte.

1.1.2 Algorithme de résolution (Approche historique)

La résolution directe du LASSO pose un problème numérique : la contrainte

$$\sum_j |\beta_j| \leq t$$

utilise des valeurs absolues, ce qui la rend non-linéaire et difficile à optimiser. Pour contourner cela, cette condition peut s'écrire comme un système de 2^p contraintes d'inégalités linéaires, correspondant à toutes les combinaisons possibles de signes pour les p coefficients β_j . Cependant, lorsque p est grand, le nombre de contraintes croît exponentiellement, en 2^p , ce qui rend leur résolution simultanée computationnellement difficile. TIBSHIRANI [1] s'appuie donc sur les travaux de LAWSON et HANSON [3] pour proposer un algorithme séquentiel. L'idée centrale est de ne pas imposer toutes les contraintes en une fois, mais de les ajouter progressivement une à une, seulement lorsqu'elles sont violées.

On résout d'abord le problème d'optimisation classique (sans la pénalité). On vérifie ensuite *a posteriori* si la solution obtenue respecte la contrainte L_1 globale. Si elle la viole, on relève la combinaison de signes exacte de cette solution, et on ajoute uniquement cette contrainte d'inégalité linéaire au problème pour l'itération suivante.

Posons

$$g(\beta) = \sum_{i=1}^N (y_i - \sum_j \beta_j x_{ij})^2$$

la fonction objectif (l'erreur) à minimiser. Posons également δ_i les vecteurs de dimension p représentant une combinaison de signes, de la forme $(\pm 1, \pm 1, \dots, \pm 1)$.

L'algorithme procède de la manière suivante :

1. **Initialisation (Le pari naïf) :** On calcule d'abord l'estimateur des moindres carrés ordinaires (noté $\hat{\beta}^o$). On définit alors l'ensemble de contraintes actives $E = \{i_0\}$, où δ_{i_0} correspond simplement au vecteur des signes de cet estimateur.
2. **Optimisation sous contrainte restreinte :** On cherche le vecteur $\hat{\beta}$ qui minimise l'erreur $g(\beta)$ tout en respectant uniquement le sous-ensemble de contraintes défini par E . Mathématiquement, cela s'écrit $G_E \beta \leq t \mathbf{1}$, où G_E est la matrice dont les lignes sont les vecteurs de signes δ_i présents dans E , et $\mathbf{1}$ est le vecteur colonne composé uniquement de 1.
3. **Vérification et itération :** On vérifie si la solution mathématique trouvée respecte les contraintes du problème initial. Autrement, tant que $\sum |\hat{\beta}_j| > t$ (c'est-à-dire que la contrainte d'origine n'est pas encore respectée) :
 - On identifie la combinaison de signes de notre solution actuelle : $\delta_i = \text{sign}(\hat{\beta})$.
 - On ajoute ce nouvel indice i à notre ensemble de contraintes actives E (l'algorithme intègre la contrainte qu'il vient de violer).
 - On recalcule un nouveau $\hat{\beta}$ minimisant $g(\beta)$, mais cette fois-ci soumis au système de contraintes mis à jour : $G_E \beta \leq t \mathbf{1}$.

L'algorithme s'arrête dès que la condition globale $\sum |\hat{\beta}_j| \leq t$ est satisfaite. À ce stade, les conditions de Karush-Kuhn-Tucker sont remplies et la solution trouvée est optimale. Bien que la limite théorique soit de 2^p itérations, Tibshirani souligne qu'en pratique, le modèle converge très rapidement, nécessitant généralement entre $0.5 \times p$ et $0.75 \times p$ étapes (page 279 de [1]).

Dans les implémentations modernes, l'algorithme le plus courant est cependant la descente coordonnée. Le principe est de fixer tous les coefficients sauf un, puis de mettre à jour ce coefficient en tenant compte de la pénalisation L_1 . Cette méthode est particulièrement adaptée au LASSO, car la mise à jour coordonnée par coordonnée peut annuler exactement certains coefficients. Elle est donc efficace numériquement et permet de calculer facilement le chemin de régularisation pour plusieurs valeurs de λ .

1.2 Choix du paramètre de régularisation par Validation Croisée

L'estimateur LASSO dépend donc fortement de son paramètre de régularisation t , qui contrôle la force de la pénalité appliquée aux coefficients.

- Si t est trop grand, la pénalité est faible, le modèle se rapproche des moindres carrés ordinaires et risque le surapprentissage (overfitting).
- Si t est trop petit, la pénalité est trop forte, de nombreux coefficients sont forcés à zéro, ce qui peut conduire à un modèle trop simpliste (underfitting), certaines informations importantes peuvent ne pas être capturées.

Pour trouver la valeur optimale de ce paramètre, qui minimise l'erreur de prédiction sur de nouvelles données, la méthode standard est la validation croisée à K blocs (*K-fold cross-validation*).

Principe de l'algorithme

Soit une grille de valeurs candidates pour λ . Pour chaque valeur de cette grille, on évalue la performance du modèle selon la procédure suivante :

1. **Partitionnement** : L'ensemble des données d'entraînement T est divisé aléatoirement en K sous-ensembles (ou "blocs") de tailles approximativement égales, notés T^v pour $v = 1, 2, \dots, K$.
2. **Apprentissage et Test itératif** : L'algorithme réalise K itérations. À chaque itération v :
 - Le bloc T^v est mis de côté et sert d'ensemble de test.
 - Le modèle LASSO est entraîné sur les $K - 1$ autres blocs restants (notés $T - T^v$).
 - On utilise le modèle ainsi entraîné pour prédire les valeurs du bloc de test T^v , et on calcule l'erreur de prédiction (généralement l'erreur quadratique moyenne), notée $PE^v(\lambda)$.
3. **Moyenne** : Une fois les K itérations terminées, on calcule l'erreur moyenne de validation croisée pour cette valeur spécifique de λ :

$$PE(\lambda) = \frac{1}{K} \sum_{v=1}^K PE^v(\lambda)$$

Sélection finale

Cette procédure est répétée pour toutes les valeurs de λ de notre grille. Le paramètre optimal $\hat{\lambda}$ retenu pour le modèle final est tout simplement celui qui minimise l'erreur moyenne de validation croisée $PE(\lambda)$. Une fois ce $\hat{\lambda}$ trouvé, le modèle final est généralement ré-entraîné sur l'intégralité du jeu de données T .

Un schéma est également proposé en annexe en figure 5 pour une représentation plus intuitive.

2 Exemple historique : Toy Example

2.1 Présentation des données simulées

On génère des données artificiellement : 20 paires (X_i, Y_i) avec $X_i \sim \mathcal{N}(0, I_8)$ et $Y_i = X_i^T \beta^* + \epsilon_i$ avec $\epsilon_i \sim \mathcal{N}(0, 1)$ et $\beta^* = (5, 3, 0, 0, 1.5, 0, 0, 0)^T$. En pratique, il est généralement crucial de standardiser les colonnes de la matrice de design $\mathbb{X}$ afin que la pénalité LASSO ne dépende pas de l'unité ou de la variance des variables explicatives. Cependant, dans notre configuration, les données étant générées selon une loi normale standard $\mathcal{N}(0, I_8)$, elles sont déjà nativement centrées et à la même échelle.

2.2 Chemin de régularisation et perspective prédictive




FIGURE 1 – Erreur de prédiction intrinsèque $\left\| \mathbb{X}(\hat{\beta}_\lambda - \beta^*) \right\|_2^2$ en fonction de λ

La figure 1 représente l'erreur de prédiction intrinsèque du modèle en fonction du paramètre de régularisation λ . L'erreur est calculée par rapport au vrai vecteur de paramètres β^* , sans le bruit ϵ .

On remarque que l'erreur augmente selon λ . L'optimum théorique se situe donc à la borne inférieure absolue. En effet, en négligeant le bruit, on aurait théoriquement $\lambda_{\text{optimal théorique}} = 0$, ce qui correspond

à l'estimateur des moindres carrés ordinaires (sans pénalité). Ici on a $\lambda_{\text{optimal}} = 0.05$

Ce comportement s'explique par deux caractéristiques majeures de la configuration de notre jeu de données simulé :

- **Un système surdéterminé et bien conditionné** : Nous nous plaçons dans un régime où le nombre d'observations est supérieur au nombre de variables ($n = 20 > d = 8$). La matrice de design $\mathbb{X} \in \mathbb{R}^{n \times d}$ étant de rang plein, la matrice de Gram $\mathbb{X}^\top \mathbb{X}$ est inversible. L'estimateur des moindres carrés (correspondant au cas $\lambda = 0$) est donc parfaitement bien défini et stable, sans que l'inversion n'amplifie excessivement les perturbations de Y .
- **Un rapport signal sur bruit très élevé** : La contribution déterministe $\mathbb{X}\beta^*$ domine largement la composante aléatoire ϵ dans le modèle $Y = \mathbb{X}\beta^* + \epsilon$. Sachant que $\mathbb{X}_i \sim \mathcal{N}(0, I_8)$ et $\epsilon_i \sim \mathcal{N}(0, 1)$, nous pouvons quantifier explicitement les variances respectives :

$$\begin{aligned} \text{Var}(\mathbb{X}\beta^*) &= \sum_{j=1}^8 (\beta_j^*)^2 \\ &= 5^2 + 3^2 + 0^2 + 0^2 + 1.5^2 + 0^2 + 0^2 + 0^2 \\ &= 25 + 9 + 2.25 = 36.25. \end{aligned}$$

La variance du bruit étant $\text{Var}(\epsilon) = 1$, le rapport signal sur bruit s'élève à $\frac{36.25}{1} = 36.25$. Les observations sont donc assez peu bruitées.

Dans ce contexte particulièrement favorable, l'ajout d'une pénalisation L_1 via le LASSO contracte les coefficients vers zéro, ce qui introduit un biais supplémentaire. Comme la variance de l'estimateur des moindres carrés est déjà limitée par la faible présence du bruit, la très légère réduction de variance potentiellement apportée par le LASSO ne suffit pas à compenser l'augmentation de ce biais. Il est donc logique d'observer les meilleures performances lorsque le modèle a une faible pénalisation. Il faut toutefois noter que cela dépend aussi grandement de la seed utilisée, un autre exemple est montré en annexe avec des résultats différents. Ce qui est logique car nous n'avons que 20 paires.

On se place désormais dans le cas où β^* n'est pas connu, on veut trouver le λ en utilisant la validation croisée.




FIGURE 2 – Sélection du paramètre λ par validation croisée (5-fold)

En utilisant une validation croisée à 5 blocs, l'algorithme cherche à minimiser l'erreur de prédiction sur de nouvelles données, en tenant compte du bruit.

Comme le montre la figure 2, le paramètre sélectionné par validation croisée est $\lambda_{CV} = 0.03$. On remarque que cette valeur est extrêmement proche de celle obtenue in-sample ($\lambda_{\text{optimal}} = 0.05$) et reste dans les deux cas très proche de zéro. Ce résultat est parfaitement cohérent et illustre le compromis biais-variance dans notre configuration spécifique. Le rapport signal sur bruit étant très élevé, le modèle

n'a besoin que d'une infime régularisation. Une pénalité très faible (autour de 0.03 - 0.05) est suffisante pour mettre à zéro les coefficients non pertinents sans introduire un biais de contraction trop important qui dégraderait les performances prédictives sur les vraies variables.

2.3 Analyse de la parcimonie (Sparsity)




FIGURE 3 – Évolution de la norme L_0 (nombre de variables actives) en fonction de λ

Le graphique de la norme L_0 (le nombre de coefficients non nuls) trace une fonction en escalier décroissante en fonction de λ (figure 3). L'introduction de la pénalité géométrique du LASSO force les coefficients à s'annuler progressivement lorsque la régularisation augmente.

En confrontant ce graphique aux paramètres précédents, on constate un phénomène intéressant :

- Que ce soit pour $\lambda_{optimal} = 0.05$ (in-sample) ou pour $\lambda_{CV} = 0.03$ (validation croisée), la norme L_0 reste très élevée, avec 7 variables actives sur 8. Les modèles optimaux en termes de prédiction ont donc peu de coefficients nuls.
- La "vraie parcimonie" du modèle ($\|\beta^*\|_0 = 3$, représentée par la ligne noire pointillée) n'est atteinte que pour une valeur de régularisation beaucoup plus forte, autour de $\lambda \approx 0.25$.

Cette observation met en évidence que le paramètre qui minimise l'erreur de prédiction (trouvé par validation croisée) ne coïncide pas nécessairement avec celui qui isole parfaitement les vraies variables explicatives. Ici, une trop grosse pénalisation imposerait un biais de contraction (shrinkage) trop sévère sur les coefficients non nuls (5, 3 et 1.5).

En annexe, on joint la valeur des coefficients en fonction de λ et les graphiques pour une autre seed.

3 Application au monde réel : Diagnostic du cancer du sein

3.1 Description du jeu de données

Le jeu de données *Breast Cancer Wisconsin (Diagnostic)* est un jeu de données médical issu du dépôt UCI Machine Learning Repository [2], mis à disposition le 31/10/1995. Il contient 569 observations correspondant à des cellules prélevées sur des masses mammaires, chacune décrite par une trentaine de variables calculées à partir d'images numérisées d'aspirats à l'aiguille fine.

Ces variables décrivent les caractéristiques morphologiques des noyaux cellulaires, comme le rayon, la texture, le périmètre, l'aire, la compacité, la concavité, la symétrie ou encore la dimension fractale.

Le dataset est cohérent avec la réalité biologique, mais il est simplifié. Il se concentre sur des caractéristiques morphologiques des noyaux cellulaires, alors qu'en pratique les médecins utilisent aussi l'imagerie,

la biopsie, l'analyse histologique complète, les biomarqueurs et les données cliniques du patient.

3.2 Modèle LASSO Logistique

La variable cible est binaire : chaque tumeur est classée comme bénigne ou maligne.

Ce jeu de données est donc naturellement adapté à un problème de classification binaire, ce qui justifie l'utilisation d'un modèle de régression logistique pénalisée par une norme ℓ_1 , plutôt qu'un LASSO linéaire classique (continu). La régression logistique ne prédit pas directement une valeur réelle : elle estime une probabilité conditionnelle, par exemple la probabilité qu'une tumeur soit maligne sachant ses caractéristiques morphologiques. Une règle de décision, souvent fondée sur un seuil de probabilité de 0.5, permet ensuite d'obtenir une classe prédite.

La pénalisation permet à la fois d'améliorer la généralisation du modèle et d'identifier les variables les plus influentes pour la prédiction du type de tumeur.

3.3 Estimateur LASSO logistique et chemin de régularisation

On considère un modèle de régression logistique pénalisé par une norme L_1 , appelé régression logistique LASSO. L'objectif est d'estimer les coefficients $\hat{\beta}_\lambda$ en minimisant une fonction de coût composée de deux termes : la perte logistique et une pénalisation proportionnelle à la somme des valeurs absolues des coefficients.

L'estimateur LASSO logistique s'écrit sous la forme :

$$\ell(\beta) = \sum_{i=1}^n \left[y_i (x_i^T \beta) - \log(1 + e^{x_i^T \beta}) \right]$$

$$\hat{\beta}_\lambda = \arg \min_{\beta} \left\{ -\ell(\beta) + \lambda \sum_{j=1}^p |\beta_j| \right\},$$

où $\ell(\beta)$ désigne la log-vraisemblance du modèle logistique, p le nombre de variables explicatives, et λ le paramètre de régularisation.

Le paramètre λ contrôle l'intensité de la pénalisation. Lorsque λ est faible, la pénalisation est peu importante : le modèle conserve beaucoup de variables et certains coefficients peuvent prendre des valeurs élevées en valeur absolue. À l'inverse, lorsque λ augmente, la pénalisation devient plus forte et les coefficients sont progressivement réduits, certains pouvant devenir exactement nuls.




FIGURE 4 – Chemin de régularisation

Le graphique 4 représente le chemin de régularisation, c'est-à-dire l'évolution des coefficients $\hat{\beta}_\lambda$ en fonction de λ . Chaque courbe correspond à une variable du jeu de données.

On observe que, pour de très faibles valeurs de λ , plusieurs coefficients sont très éloignés de zéro. Certaines variables ont donc une forte influence initiale sur la prédiction. Ensuite, lorsque λ augmente, les coefficients se rapprochent rapidement de zéro. Cela illustre bien l'effet de la pénalisation LASSO : elle réduit l'amplitude des coefficients et favorise la sélection de variables.

On remarque également qu'à partir d'une certaine valeur de λ , environ autour de $\lambda \simeq 0.5$, les courbes deviennent presque constantes. Les coefficients évoluent alors très peu lorsque λ continue d'augmenter. Cela signifie que le modèle entre dans une zone de stabilité : les variables les moins importantes ont déjà été fortement pénalisées, tandis que seules les variables les plus pertinentes conservent un coefficient non nul ou proche de zéro.

Les variables qui semblent les plus importantes sont celles dont les coefficients restent les plus éloignés de zéro en valeur absolue lorsque la régularisation augmente. Notons que ces observations sur le chemin de régularisation sont confirmées par les performances du modèle évalué en section 3.5 (accuracy $\approx 96.5\%$), ce qui valide l'interprétation des coefficients suivante. D'après le chemin de régularisation et les coefficients obtenus par le modèle, les variables les plus influentes pour la prédiction du type de tumeur sont :

radius3, radius2, area2, texture3, area3, concave_points3.
concavity3, perimeter3, concave_points1.

Ces variables correspondent principalement à des caractéristiques géométriques de la tumeur, comme le rayon, l'aire, la concavité et les points concaves. Les variables sélectionnées par le logistic LASSO sont cohérentes avec l'interprétation biologique. En médecine, les cellules cancéreuses présentent souvent des noyaux plus grands, plus irréguliers et moins homogènes. Le fait que le modèle retienne des variables comme `radius_worst`, `area_worst`, `perimeter_worst` ou `concave_points_worst` montre qu'il utilise justement ces différences morphologiques pour distinguer les tumeurs bénignes et malignes.

Ainsi, le chemin de régularisation montre que le LASSO permet non seulement de construire un modèle de classification, mais aussi d'identifier les variables les plus pertinentes. Il rend donc le modèle plus interprétable en éliminant les variables les moins utiles et en mettant en évidence les caractéristiques les plus discriminantes pour la prédiction du type de tumeur.

3.4 Choix de λ par validation croisée

La validation croisée permet de déterminer la valeur optimale du paramètre de régularisation. Dans notre implémentation avec `scikit-learn`, le paramètre utilisé est C , qui est inversement lié à l'intensité de la régularisation. Avec notre grille de validation croisée, on obtient :

$$C = 1.2048, \quad \lambda = \frac{1}{C} \simeq 0.8300.$$

Comme C est l'inverse de l'intensité de régularisation, cette valeur correspond à une régularisation modérée.

Pour cette valeur du paramètre de régularisation, **le modèle LASSO sélectionne 21 variables actives sur 30**. Les coefficients associés sont les suivants :

Variable	Coef.	Variable	Coef.
radius3	1.8236	smoothness3	0.6669
radius2	1.7479	concavity1	0.3848
area2	1.6845	smoothness2	0.2561
texture3	1.4939	texture2	-0.2490
area3	1.3268	fractal_dimension2	-0.2447
concave_points3	1.2607	texture1	0.2270
concavity3	1.0371	fractal_dimension1	-0.1725
perimeter3	1.0211	symmetry2	-0.1028
concave_points1	0.9649	compactness1	-0.0791
compactness2	-0.9486	concave_points2	0.0270
symmetry3	0.6693		

TABLE 1 – Variables actives sélectionnées par le LASSO logistique pour $C = 1.2048$, soit $\lambda \simeq 0.8300$.

3.5 Évaluation des prédictions sur un ensemble de test

L'analyse des coefficients permet d'identifier les variables importantes, mais elle ne suffit pas à montrer que le modèle prédit correctement sur de nouvelles données. Nous évaluons donc également les prédictions sur un ensemble de test indépendant, noté X_{test} . Les données sont séparées en un ensemble d'entraînement et un ensemble de test, puis le paramètre de régularisation est choisi par validation croisée sur l'ensemble d'entraînement.

Pour le modèle Logistic LASSO, nous obtenons sur l'ensemble de test une accuracy d'environ 0.965, une AUC d'environ 0.997, une sensibilité pour la classe maligne d'environ 0.925 et une spécificité d'environ 0.989. La matrice de confusion correspondante est :

		Prédit	
		Malin	Bénin
Réal	Malin	49	4
	Bénin	1	89

Le modèle commet peu d'erreurs sur l'ensemble de test. Les 4 faux négatifs (tumeurs malignes classées comme bénignes) sont cliniquement les plus préoccupants, car ils pourraient conduire à un retard de prise en charge.

3.6 Interprétation des variables sélectionnées

Le modèle LASSO sélectionne 21 variables sur 30, ce qui signifie qu'environ un tiers des variables ont été éliminées. Cela met en évidence la capacité du LASSO à effectuer une sélection automatique de variables.

La majorité des variables retenues sont liées à la taille et à la forme de la tumeur, telles que le rayon (`radius`), l'aire (`area`), le périmètre (`perimeter`), la concavité (`concavity`) et les points concaves (`concave_points`). Cela est cohérent d'un point de vue médical, car ces caractéristiques sont essentielles pour distinguer une tumeur bénigne d'une tumeur maligne.

Les variables ayant les coefficients les plus élevés, comme `radius3`, `radius2`, `area2` et `texture3`, sont celles qui influencent le plus la prédiction.

Ainsi, l'ensemble des variables sélectionnées est à la fois réduit et interprétable, ce qui permet d'identifier les caractéristiques les plus pertinentes pour la classification des tumeurs.

3.7 Stabilité de sélection des variables

Afin d'évaluer la robustesse de la sélection de variables effectuée par le LASSO, nous avons réalisé une analyse de stabilité par bootstrap. Le principe consiste à rééchantillonner plusieurs fois le jeu de données avec remise, puis à réentraîner un modèle Logistic LASSO sur chaque échantillon bootstrap. Pour chaque variable, on calcule alors la fréquence à laquelle son coefficient est non nul.

Cette approche permet de distinguer les variables sélectionnées de manière stable, donc probablement réellement informatives, des variables sélectionnées uniquement à cause des fluctuations de l'échantillon.

Les résultats montrent que certaines variables sont sélectionnées dans une très grande majorité des échantillons bootstrap. Par exemple, les fréquences de sélection les plus élevées sont approximativement :

`smoothness3` : 0.98, `texture3` : 0.98, `concave_points3` : 0.96, `radius3` : 0.93, `radius2` : 0.90.

Cela confirme que ces caractéristiques constituent les variables les plus robustes pour la discrimination entre tumeurs bénignes et malignes. À l'inverse, certaines variables ayant des coefficients plus faibles apparaissent de manière moins stable, ce qui suggère qu'elles jouent un rôle secondaire dans la prédiction. Cette analyse complète donc le chemin de régularisation en apportant une mesure de fiabilité de la sélection de variables réalisée par le LASSO.

3.8 Comparaison entre LASSO, Ridge et Elastic Net

Voir annexe

3.9 Extension : cadre haute dimensionnel (GSE96058)

Voir annexe

4 Conclusion

Dans ce projet, nous avons étudié l'estimateur LASSO à la fois du point de vue théorique et du point de vue computationnel. Le LASSO ajoute une pénalisation L_1 qui réduit les coefficients et peut en annuler certains exactement. Cette propriété permet d'obtenir des modèles parcimonieux et plus interprétables.

L'exemple simulé inspiré de [1] illustre le compromis entre performance prédictive et parcimonie. Lorsque le vrai paramètre β^* est connu, une très faible régularisation peut être optimale du point de vue de l'erreur intrinsèque. En revanche, lorsque β^* est inconnu, la validation croisée sélectionne un paramètre de régularisation strictement positif, ce qui permet d'obtenir un modèle plus simple et plus stable.

Sur le jeu de données *Breast Cancer Wisconsin*, la régression logistique pénalisée par une norme L_1 est adaptée car la variable cible est binaire. Le modèle sélectionne 21 variables morphologiques sur 30 liées notamment au rayon, à l'aire, à la concavité et aux points concaves. De plus, le modèle atteint une accuracy de 96.5% et une AUC de 0.997 sur l'ensemble de test, confirmant que la parcimonie n'est pas obtenue au détriment des performances (Figure 6).

Ainsi, le Logistic LASSO constitue dans ce contexte un bon compromis entre précision de classification, sélection automatique de variables et interprétation des caractéristiques les plus discriminantes.

Par ailleurs, notre ouverture sur les profils d'expression génique (GSE96058) a permis de confirmer la robustesse de cette méthode dans un cadre de grande dimension ($p \gg n$). Face à plus de 28 000 gènes candidats, la pénalisation L_1 parvient à isoler efficacement une infime fraction de variables pertinentes (environ 5%), tout en conservant d'excellentes métriques de classification. Cette extension démontre que le LASSO dépasse la simple sélection de variables sur des jeux de données classiques pour s'imposer comme un outil incontournable capable d'extraire un signal clinique fort dans des problèmes de très haute dimension

Références

- [1] R. TIBSHIRANI, « Regression Shrinkage and Selection Via the Lasso, » *Journal of the Royal Statistical Society : Series B (Methodological)*, t. 58, n° 1, p. 267-288, jan. 1996, ISSN : 0035-9246. DOI : 10.1111/j.2517-6161.1996.tb02080.x
- [2] W. WOLBERG, O. MANGASARIAN et W. N. STREET, *Breast Cancer Wisconsin (Diagnostic)*, UCI Machine Learning Repository, 1995. DOI : 10.24432/C5DW2B
- [3] C. L. LAWSON et R. J. HANSON, *Solving Least Squares Problems*. Englewood Cliffs, NJ : Prentice-Hall, 1974.
- [4] C. BRUEFFER et al., « Clinical Value of RNA Sequencing-Based Classifiers for Prediction of the Five Conventional Breast Cancer Biomarkers : A Report From the Population-Based Multicenter Sweden Cancerome Analysis Network—Breast Initiative, » *JCO Precision Oncology*, t. 2, p. 1-18, 2018, PMID : 32913985. DOI : 10.1200/P0.17.00135

A Cross Validation




FIGURE 5 – Représentation visuelle de la Cross Validation

B Application au monde réel : Diagnostic du cancer du sein

B.1 Comparaison entre LASSO, Ridge et Elastic Net

Nous avons également comparé les performances de trois méthodes de régularisation dans la table 2 : Ridge (L_2), LASSO (L_1) et Elastic Net ($L_1 + L_2$).

Le modèle Ridge conserve toutes les variables mais réduit leur amplitude grâce à une pénalisation quadratique. Il offre généralement une bonne stabilité numérique mais ne permet pas de sélection automatique de variables.

Le LASSO produit au contraire des modèles plus parcimonieux en annulant certains coefficients. Il améliore donc fortement l'interprétabilité du modèle.

Enfin, Elastic Net combine les deux approches. Il conserve l'effet de sélection du LASSO tout en limitant certains problèmes de stabilité pouvant apparaître lorsque les variables sont fortement corrélées.

Dans notre cas, les trois méthodes obtiennent des performances de classification similaires sur le jeu de données Breast Cancer Wisconsin. Les résultats obtenus sur l'ensemble de test sont résumés dans le tableau suivant :

Méthode	Accuracy	AUC	Nombre de variables sélectionnées
Ridge (L_2)	0.965	0.997	30
LASSO (L_1)	0.965	0.997	21
Elastic Net	0.965	0.997	28

TABLE 2 – Comparaison de Ridge, LASSO et Elastic Net sur l'ensemble de test.

Cependant Ridge conserve l'ensemble des variables; LASSO fournit le modèle le plus interprétable; Elastic Net offre un compromis intéressant entre stabilité et parcimonie. Le Logistic LASSO apparaît donc comme un bon compromis dans ce projet, car il permet à la fois une excellente capacité de classification et une interprétation claire des variables importantes.

B.2 Extension : cadre haute dimensionnel (GSE96058)

Pour illustrer la pertinence du LASSO dans un contexte génomique réel, nous l'avons appliqué au jeu de données SCAN-B / GSE96058 [4], qui contient des profils d'expression RNA-seq de 3 273 tumeurs mammaires humaines ($\approx 30\,000$ gènes mesurés par échantillon). La tâche consiste à prédire le statut du récepteur aux œstrogènes (ER), biomarqueur clinique binaire essentiel au choix thérapeutique. Ce cadre $p \gg n$ est particulièrement adapté au LASSO : la pénalisation L_1 force une sélection automatique des gènes les plus pertinents parmi des dizaines de milliers de candidats.

Notre modèle obtient une accuracy de 95.1% et une AUC de 0.953 sur l'ensemble de test ($\lambda^* \approx 15.85$). Le LASSO ne retient que 1 546 gènes parmi les 28 562 disponibles (après filtrage des réplicats et des gènes à variance nulle), soit environ 5% du total. La matrice de confusion montre que les tumeurs ER+ sont

très bien identifiées (541/567 correctes), tandis que les tumeurs ER– restent plus difficiles à détecter (44/48), ce qui s’explique par leur faible représentation (figure 6). Ce résultat confirme que le LASSO reste efficace en haute dimension.




FIGURE 6 – Résultats du LASSO logistique sur GSE96058. *Gauche* : coefficients des 20 gènes les plus influents sélectionnés parmi 28 562 ($\lambda^* \approx 15.85$, 1 546 gènes actifs au total). *Droite* : matrice de confusion sur l’ensemble de test (accuracy = 95.1%, AUC = 0.953).

C Chemin de régularisation




FIGURE 7 – Chemin de régularisation

D Génération des figures avec la seed 67




FIGURE 8 – Chemin de régularisation




FIGURE 9 – Chemin de régularisation




FIGURE 10 – Chemin de régularisation




FIGURE 11 – Chemin de régularisation

Ici, contrairement à l'exemple détaillé dans la partie 2, cette nouvelle configuration aboutit à une sélection de variables et à un paramètre λ optimal sensiblement différents, ce qui met en évidence la forte sensibilité du modèle à la génération aléatoire lorsque le nombre d'observations est restreint.